BeliefKV：面向动态 Agent 工作流的 KV 管理

动态依赖感知 / 预测性迁移 / 原生执行协同

(a) Agent 执行框架



事件：SPAWN、工具调用、RETURN、JOIN
信号：收尾通知、已输出正文
进度：已观测 decode 与 GPU 服务

因果状态更新

在线观测

(b) 因果状态

运行时工作流依赖图
JOIN_ALL / 工具等待 / 可执行
Context 身份与版本

WAIT_JOIN　READY

(c) 预测模块

Child 阶段与剩余工作量
正文、通知与 decode 进度

工具剩余时间分布
类型、已执行时间与历史

提示

(d) Runtime 决策

安全 checkpoint 与有效 Host 副本
容量与传输服务成本
缺失页迁移规划
准入、驻留保护与请求老化

容量 / ACK / 首次复用

调度意图

(e) SGLang：物理缓存与执行事实源

原生 GPU 批处理 → Radix / HiCache / Allocators → HBM FULL + Mamba ⇄ (D2H / H2D) ⇄ Host FULL + Mamba

模型估计完成进度，runtime 决定动作，原生数据依赖决定执行。