从完成信号到可被执行消费的预取

分离剩余工作量、调度机会与物理数据依赖

Child 在线观测
通知、正文与 decode 进度
仅使用已经送达的信息

→

阶段 / 工作量模型
最终报告或继续调用工具
条件剩余生成工作量

→

预测输出
阶段分数与剩余 token 区间
已观测 EOS 作为独立信号

工具在线观测
工具类型、已执行时间、历史
历史仅来自已完成调用

→

剩余时间模型
以工具仍在执行为条件
随新观测滚动更新

→

预测输出
剩余时间 CDF / 时间区间
不学习离线不可识别的净收益

(a) Runtime 将预测提示转为有界动作

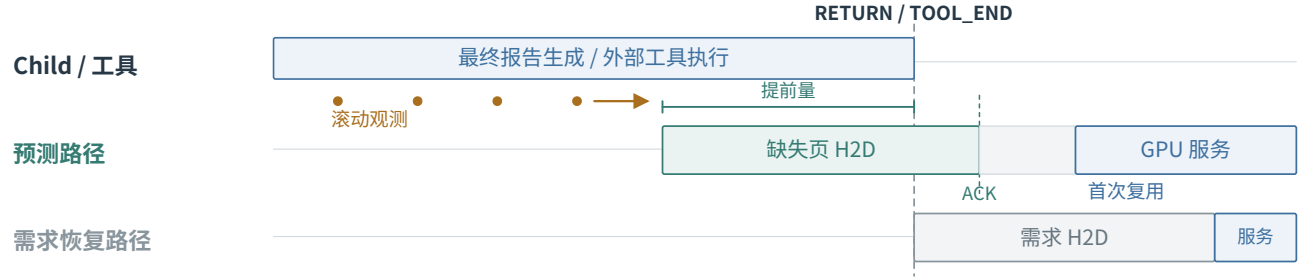
因果就绪
JOIN / 工具状态

可复用 checkpoint
有效 Host 缺失页

容量与传输成本
FULL / Mamba / H2D

执行机会
准入与驻留保护

(b) 与工具等待或最终生成区间重叠



示意图，非实测加速。部分传输重叠也可利用；执行遵循原生数据依赖。