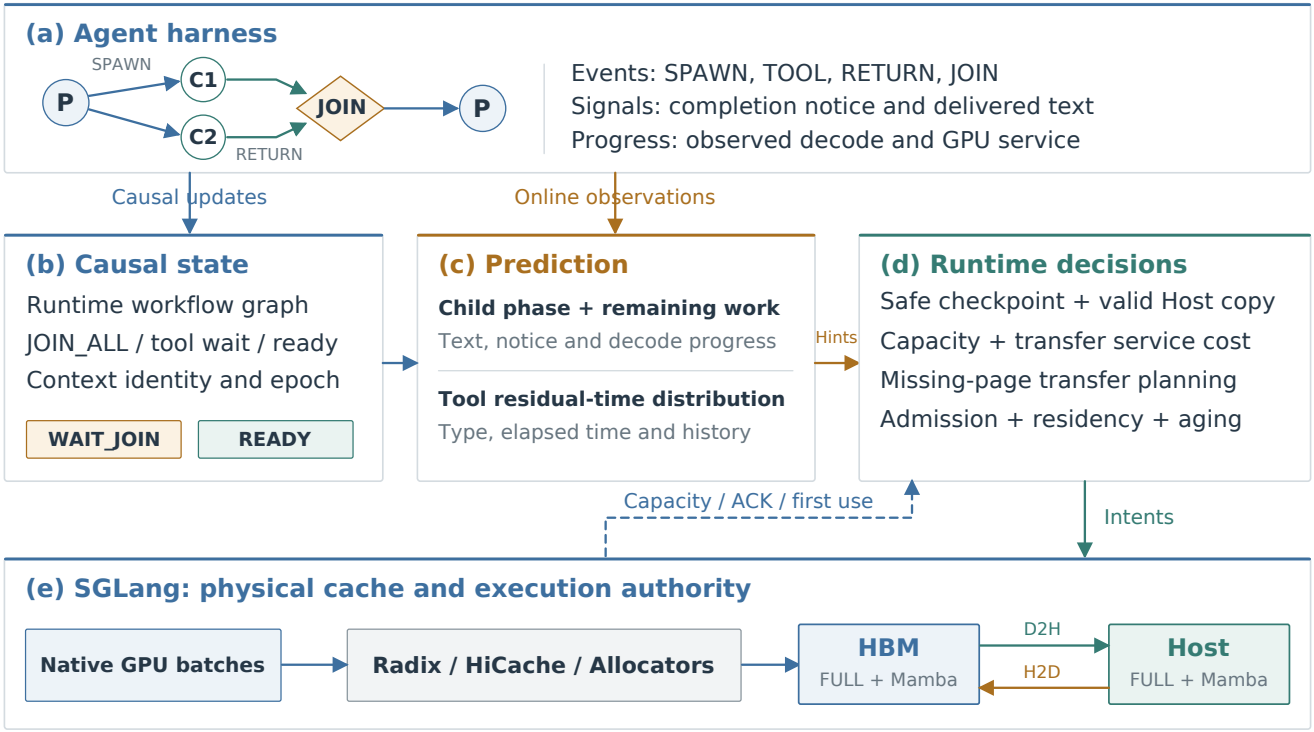
BeliefKV: Workflow-aware KV Management

Dynamic dependencies / Predictive transfers / Native execution



Models estimate completion; runtime selects actions; native dependencies govern execution.

BeliefKV：面向动态 Agent 工作流的 KV 管理

动态依赖感知 / 预测性迁移 / 原生执行协同

(a) Agent 执行框架



事件：SPAWN、工具调用、RETURN、JOIN
信号：收尾通知、已输出正文
进度：已观测 decode 与 GPU 服务

因果状态更新

在线观测

(b) 因果状态

运行时工作流依赖图
JOIN_ALL / 工具等待 / 可执行
Context 身份与版本

WAIT_JOIN　READY

(c) 预测模块

Child 阶段与剩余工作量
正文、通知与 decode 进度

工具剩余时间分布
类型、已执行时间与历史

提示

(d) Runtime 决策

安全 checkpoint 与有效 Host 副本
容量与传输服务成本
缺失页迁移规划
准入、驻留保护与请求老化

容量 / ACK / 首次复用

调度意图

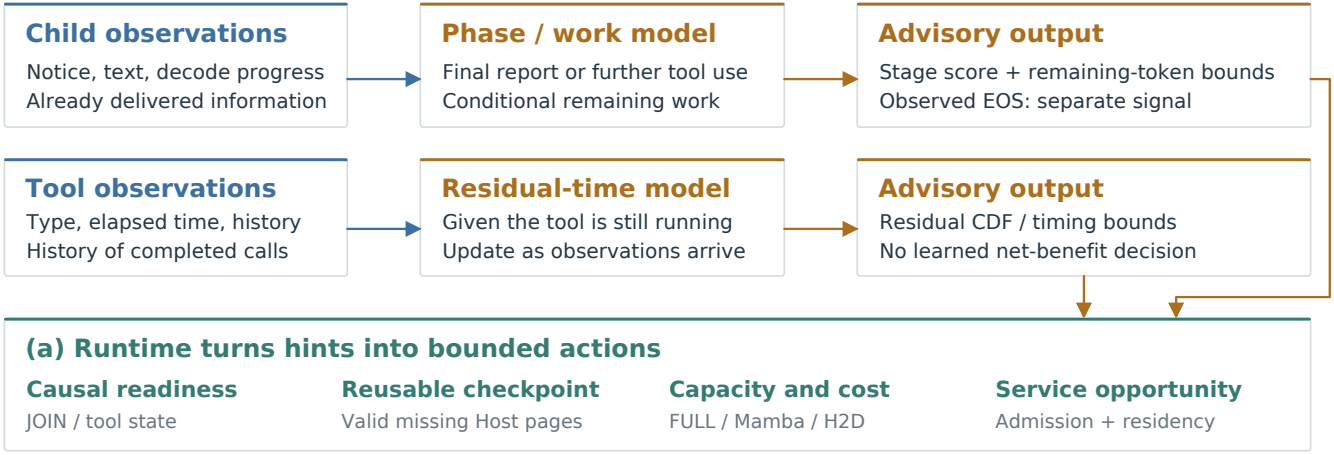
(e) SGLang：物理缓存与执行事实源

原生 GPU 批处理 → Radix / HiCache / Allocators → HBM FULL + Mamba ⇄ (D2H / H2D) ⇄ Host FULL + Mamba

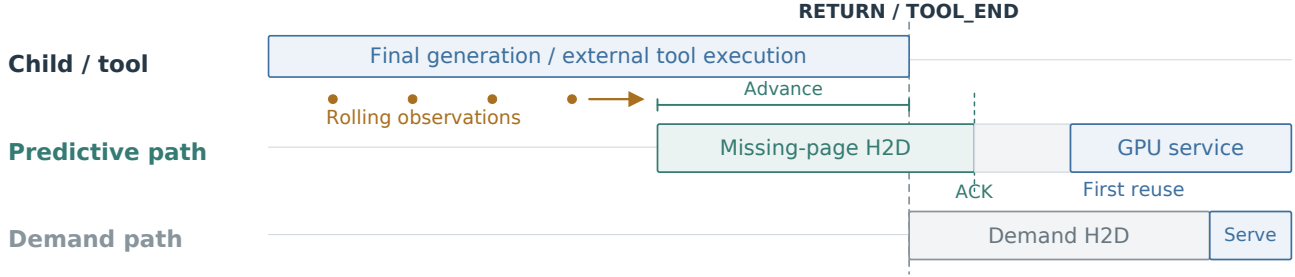
模型估计完成进度，runtime 决定动作，原生数据依赖决定执行。

From Completion Signals to Useful Prefetch

Separate remaining work, scheduling opportunity and physical data dependencies



(b) Overlap with the observed wait or final-generation interval



Schematic, not measured speedup. Partial overlap is useful; native data dependencies govern execution.

从完成信号到可被执行消费的预取

分离剩余工作量、调度机会与物理数据依赖

Child 在线观测
通知、正文与 decode 进度
仅使用已经送达的信息

→

阶段 / 工作量模型
最终报告或继续调用工具
条件剩余生成工作量

→

预测输出
阶段分数与剩余 token 区间
已观测 EOS 作为独立信号

工具在线观测
工具类型、已执行时间、历史
历史仅来自已完成调用

→

剩余时间模型
以工具仍在执行为条件
随新观测滚动更新

→

预测输出
剩余时间 CDF / 时间区间
不学习离线不可识别的净收益

(a) Runtime 将预测提示转为有界动作

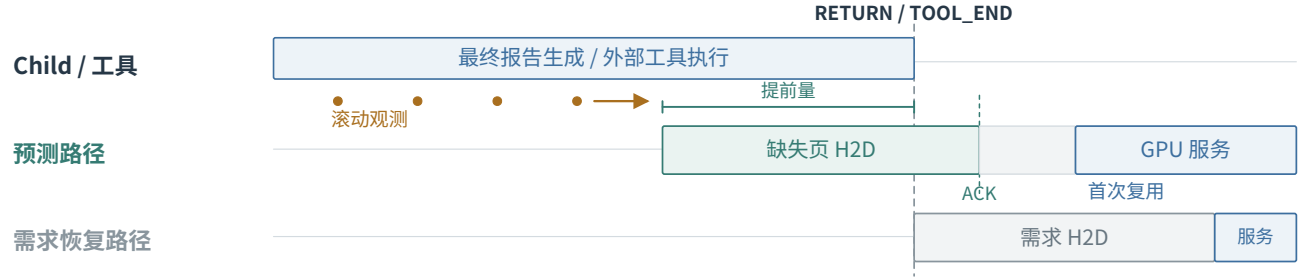
因果就绪
JOIN / 工具状态

可复用 checkpoint
有效 Host 缺失页

容量与传输成本
FULL / Mamba / H2D

执行机会
准入与驻留保护

(b) 与工具等待或最终生成区间重叠

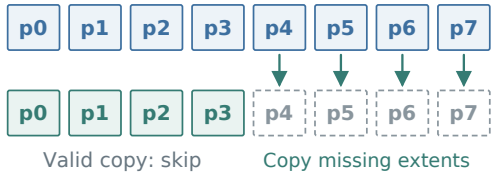


示意图，非实测加速。部分传输重叠也可利用；执行遵循原生数据依赖。

Incremental Migration and Child-to-Parent Capacity Handoff

Agent semantics select the beneficiary; native pages define the physical transfer

(a) Incremental FULL backup



PREPARE_HOST: missing FULL; HBM remains resident.

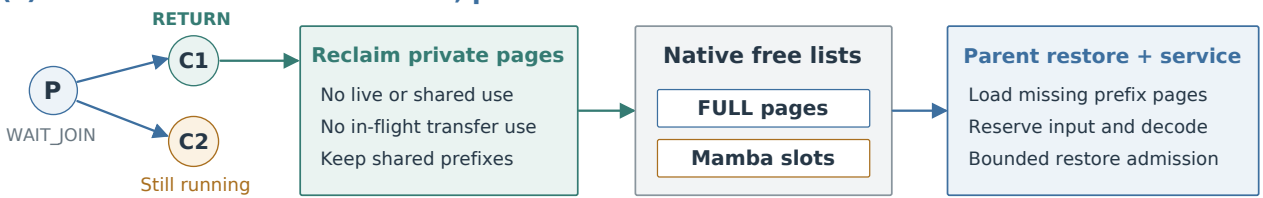
(b) Necessary Mamba checkpoint



Select the required checkpoint state

No speculative Mamba in PREPARE_HOST.
Native cache retains other valid states.

(c) Coordinate child reclamation, parent restore and admission

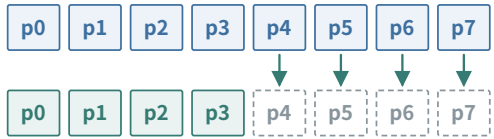


Earlier siblings can enable pre-RETURN H2D. The last child's capacity is available only after completion.
Reclaimed capacity uses native allocation; shared and still-live pages remain intact.

增量迁移与 Child → Parent 容量交接

Agent 语义选择受益对象，原生页决定实际迁移范围

(a) FULL 增量备份



PREPARE_HOST 仅备份缺失 FULL；备份本身不释放 HBM。

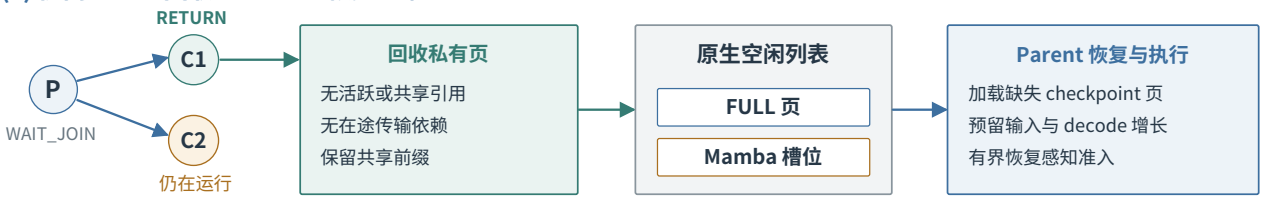
(b) 必要 Mamba checkpoint



选择目标 checkpoint 所需状态

PREPARE_HOST 不投机备份 Mamba。
其他有效状态仍由原生缓存管理。

(c) 协同 Child 回收、Parent 恢复与准入



较早结束的 sibling 可支持 RETURN 前预取；最后一个 child 的容量只能在结束后使用。
回收容量通过原生分配器使用；共享页与仍在执行的页面保留。