项目介绍

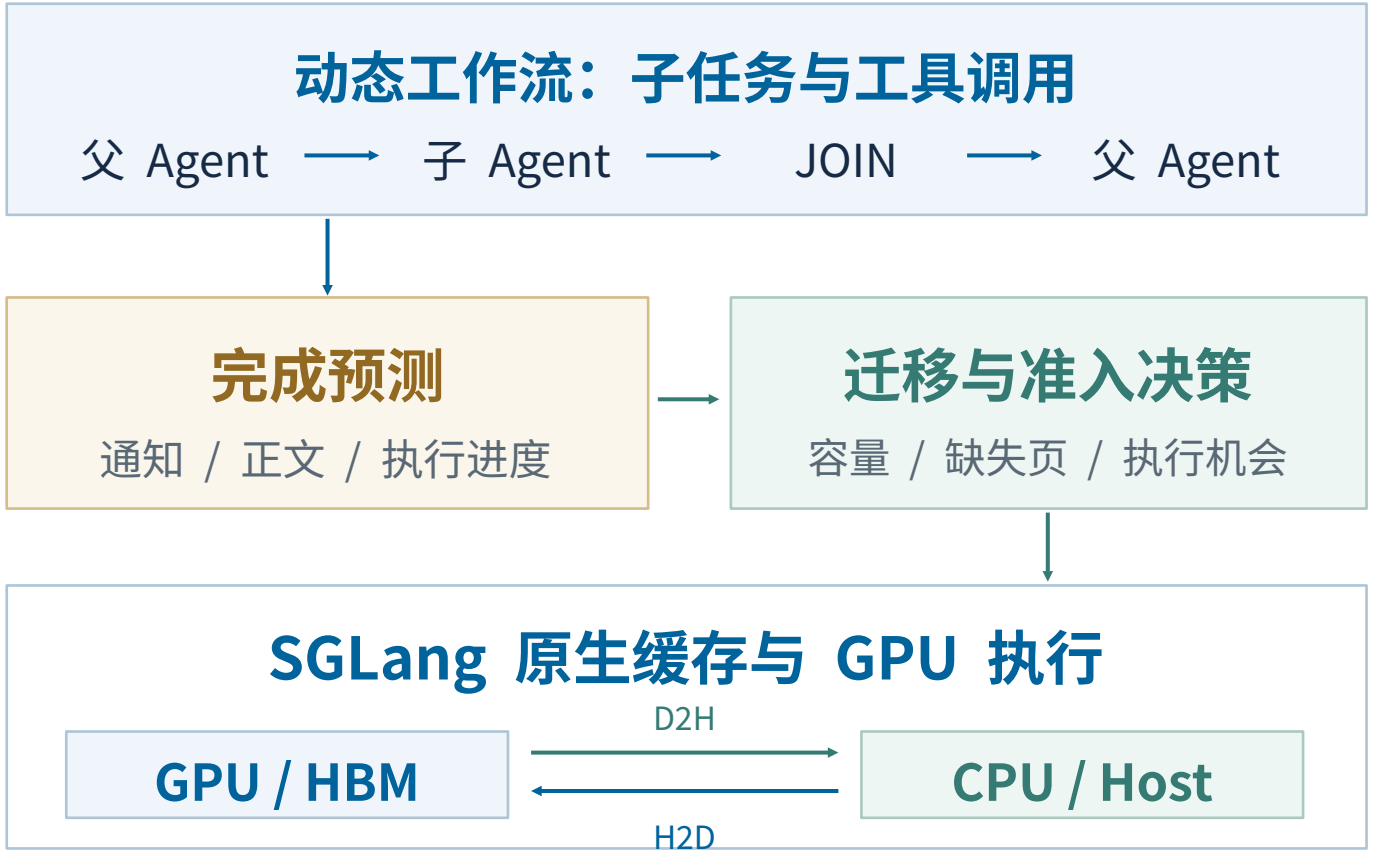
BeliefKV

动态 Agent 工作流的
预测式 KV 管理与调度

场景 子任务与工具等待交错，
KV 在 HBM / Host 间迁移。

方法 观测收尾信号，提前准备
下一次执行所需的 KV 。

目标 减少恢复等待，提高吞吐，
缩短工作流完成时间。



按缺失页迁移，恢复后及时执行

上月工作总结

08.15 - 08.31

- **建立工作流与调度基础**
  因果图、原生 subagent 、 JOIN 后 parent 上下文连续性。

09.01 - 09.21

- **贯通预测式 KV 迁移**
  接通 D2H / H2D 、传输确认、驻留与生命周期管理。

09.22 - 09.27

- **完成混合缓存适配与离线建模**
  适配 FULL / Mamba ； 完成 trace 采集、训练与项目隔离校准。

09.28 - 10.04

- **转向事件与内容驱动的预测**
  结合通知、正文和 decode 进度，拆分剩余工作与排队等待。

10.05 - 10.11

- **推进原生对照与系统性能优化**
  优化增量备份、缺失页恢复、恢复后准入和 child 容量交接。

目前：机制链路已贯通，稳定的端到端性能优势仍待验证。

下月目标

聚焦：让预测式 KV 迁移带来可验证的端到端收益

01　提高有效预取覆盖

优化 child / tool 完成预测，让更多缺失 FULL 页在返回前恢复并被复用。

02　恢复与调度协同，降低额外开销

协调容量回收、驻留和准入，减少重复加载、恢复后排队与控制成本。

03　建立公平、稳定的性能证据

固定配置对比原生 SGLang，多轮汇总吞吐、完成时间与重算情况。

验收：提高繁忙窗口与成功工作流吞吐，同时降低完成时间。