# 项目介绍

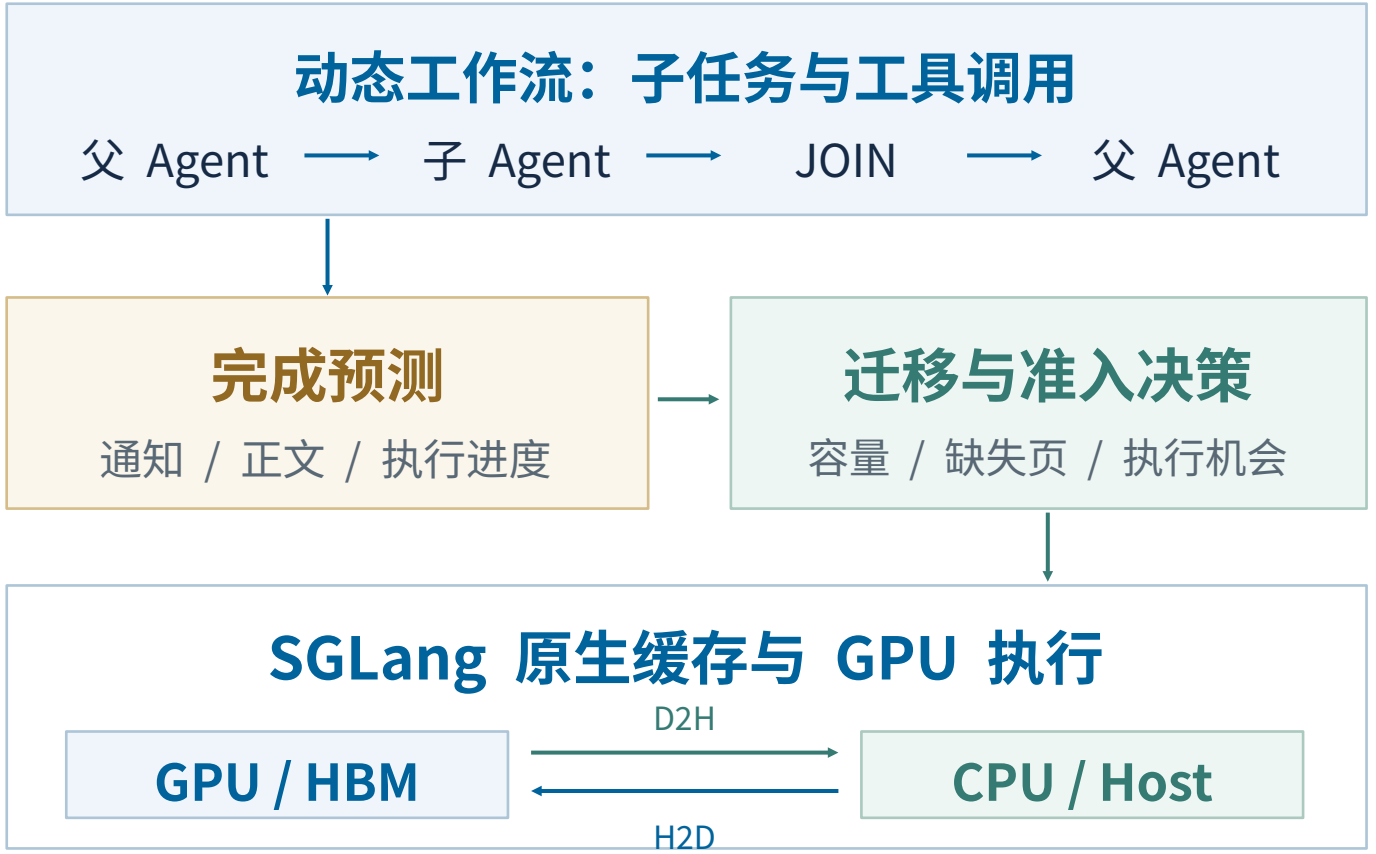
## BeliefKV

### 动态 Agent 工作流的预测式 KV 管理与调度

**场景** 子任务、工具与 JOIN 交错，KV 在 HBM / Host 间迁移。

**方法** 依据收尾信号与执行进度，提前备份、预取并安排执行。

**目标** 减少恢复等待与重复搬运，提高吞吐、降低完成时间。




按缺失页迁移，恢复后及时执行

# 上月工作总结

**08.15 - 08.31**

- **建立工作流与调度基础**
  实现因果前沿、原生 subagent 与 JOIN 后 parent 上下文连续性。

**09.01 - 09.21**

- **贯通预测式 KV 迁移**
  接通预测 D2H / H2D 、传输 ACK 、驻留租约与物理恢复生命周期。

**09.22 - 09.27**

- **完成混合缓存适配与离线建模**
  适配 FULL / Mamba ；完善传输埋点，完成训练与项目隔离校准。

**09.28 - 10.04**

- **转向事件与内容驱动的预测**
  结合通知、语义、长度与 decode 进度，建立阶段与剩余工作预测。

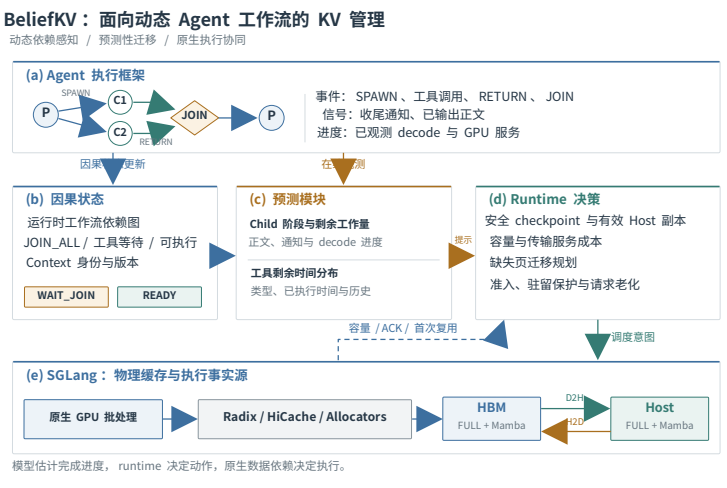
**10.05 - 10.11**

- **推进原生对照与系统性能优化**
  原生对照与两波到达；优化增量备份、缺失页恢复、准入与容量交接。

**目前：机制链路已贯通，稳定的端到端性能优势仍待验证。**

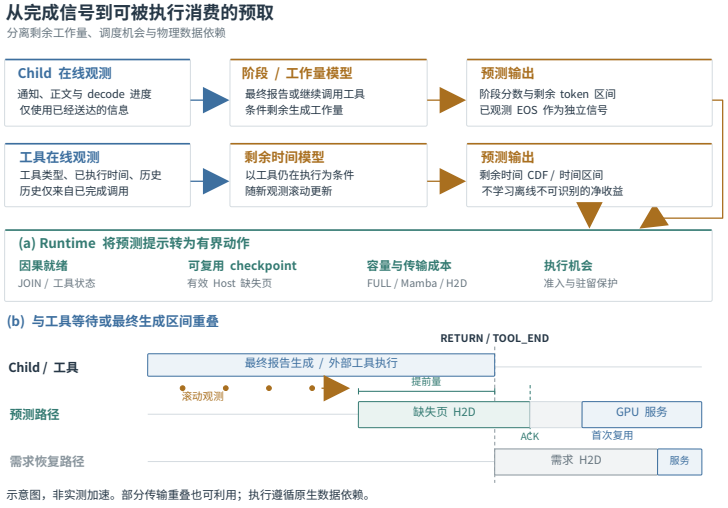
# 关键进展

## 01 系统总体架构



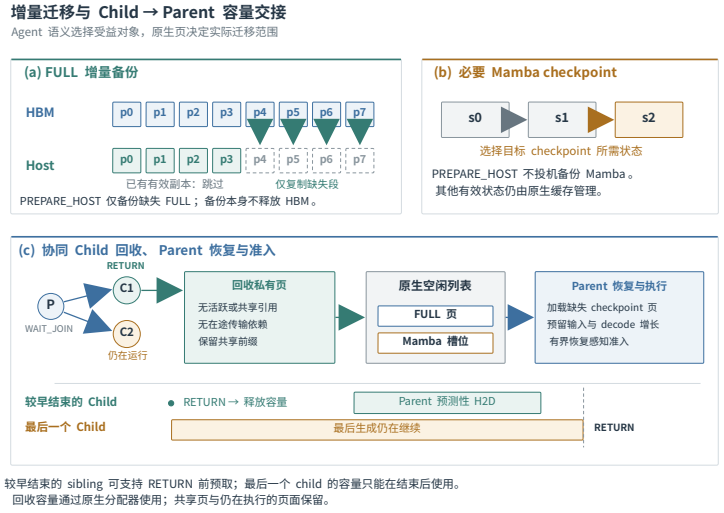

工作流事件、完成预测与运行时决策连接 KV 迁移和 SGLang 原生执行。

## 02 预测与调度协同




通知、正文与服务进度滚动更新，结合容量与准入决定 H2D 时机。

## 03 增量迁移与容量交接




较早结束的 sibling 可支持 RETURN 前预取；最后一个 child 的容量只能在结束后使用。
回收容量通过原生分配器使用；共享页与仍在执行的页面保留。

FULL 增量备份、必要状态恢复，衔接 child 释放容量与 parent 执行。

**完成了从工作流语义、预测时序到物理缓存与执行的系统贯通。**

# 阶段结论与优化重点

## 从机制贯通，走向可验证的端到端收益

**01** **预测：识别执行阶段，滚动估计剩余工作**

结合收尾通知、正文语义与 decode 进度判断 child 是否临近 RETURN 。
把排队等待单独交给运行时，避免与剩余生成工作混在一起。

**02** **迁移：按可复用缺失页恢复，协调容量与准入**

实现 FULL 增量 PREPARE 、必要 Mamba 状态恢复与驻留保护。
联动恢复感知准入与 child 容量交接，减少恢复后再次驱逐。

**03** **评估：追踪提前恢复与下一请求的实际复用**

区分预测 H2D 、需求 handoff 与原生加载，补齐首次复用归因。
优先降低控制开销、 ACK 后等待与重复恢复，检验吞吐净收益。

**当前：机制与证据链已具备，稳定的原生对照性能优势仍待验证。**

# 下月目标

## 聚焦：让预测式 KV 迁移带来可验证的端到端收益

**01** **提高有效预取覆盖**

融合通知、正文与 decode 进度，改善 child / tool 完成预测。
覆盖更多 Host-only FULL 页，统计返回前恢复与下一请求实际复用。

**02** **恢复与调度协同，降低额外开销**

联动容量回收、驻留与准入，减少重复加载和 ACK 后排队。
削减候选检查、前缀扫描与控制交付成本，避免抵消迁移收益。

**03** **建立公平、稳定的性能证据**

同版本、同负载对比原生 SGLang，正式实验采用多轮平均。
综合报告繁忙窗口吞吐、成功工作流吞吐、配对 JCT 与重算。

**验收：提高繁忙窗口与成功工作流吞吐，同时降低完成时间。**