项目介绍

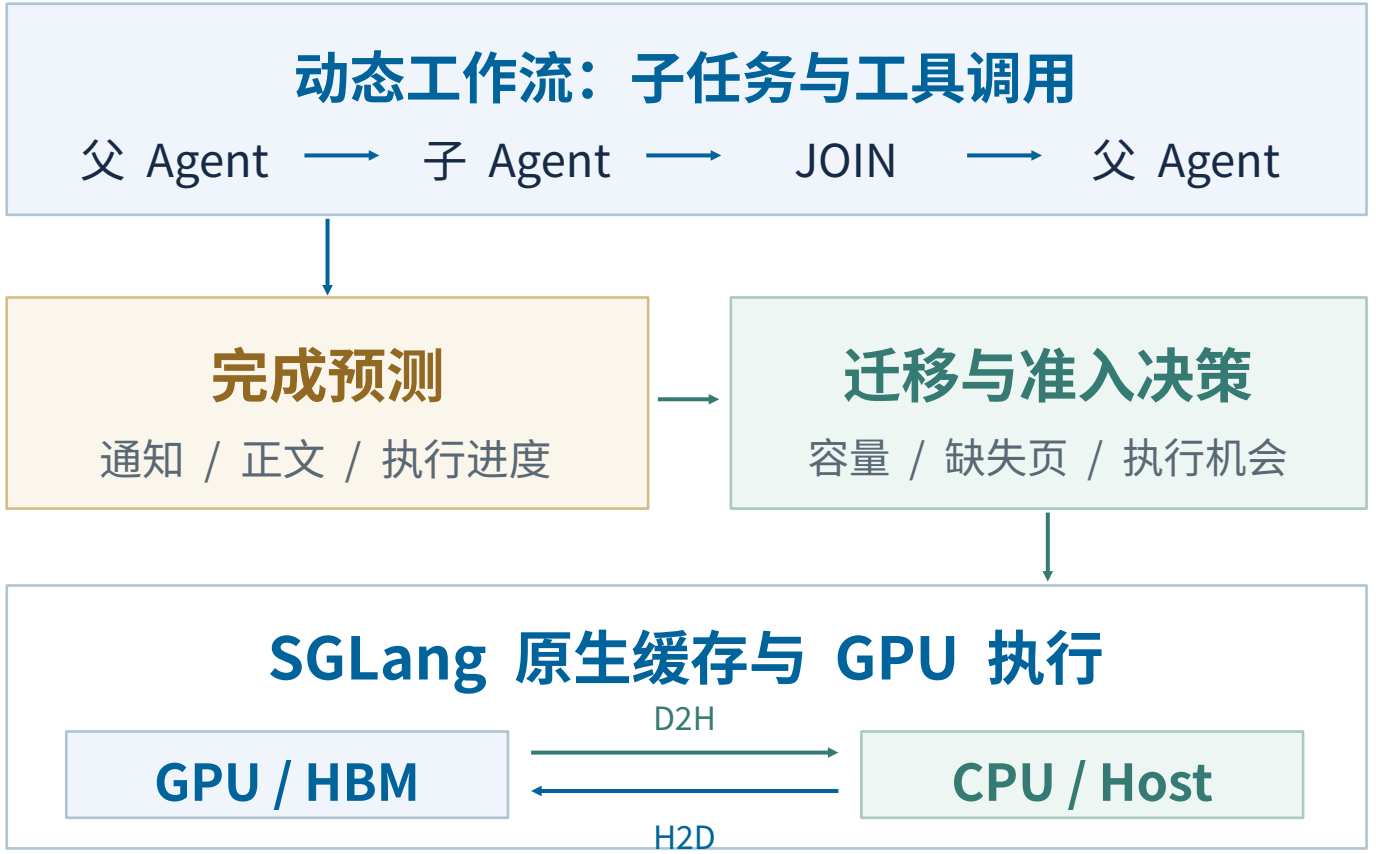
BeliefKV

动态 Agent 工作流的预测式 KV 管理与调度

场景 子任务、工具与 JOIN 交错，KV 在 HBM / Host 间迁移。

方法 依据收尾信号与执行进度，提前备份、预取并安排执行。

目标 减少恢复等待与重复搬运，提高吞吐、降低完成时间。



按缺失页迁移，恢复后及时执行

上月工作总结

08.15 - 08.31

- **建立工作流与调度基础**
  实现因果前沿、原生 subagent 与 JOIN 后 parent 上下文连续性。

09.01 - 09.21

- **贯通预测式 KV 迁移**
  接通预测 D2H / H2D 、传输 ACK 、驻留租约与物理恢复生命周期。

09.22 - 09.27

- **完成混合缓存适配与离线建模**
  适配 FULL / Mamba ；完善传输埋点，完成训练与项目隔离校准。

09.28 - 10.04

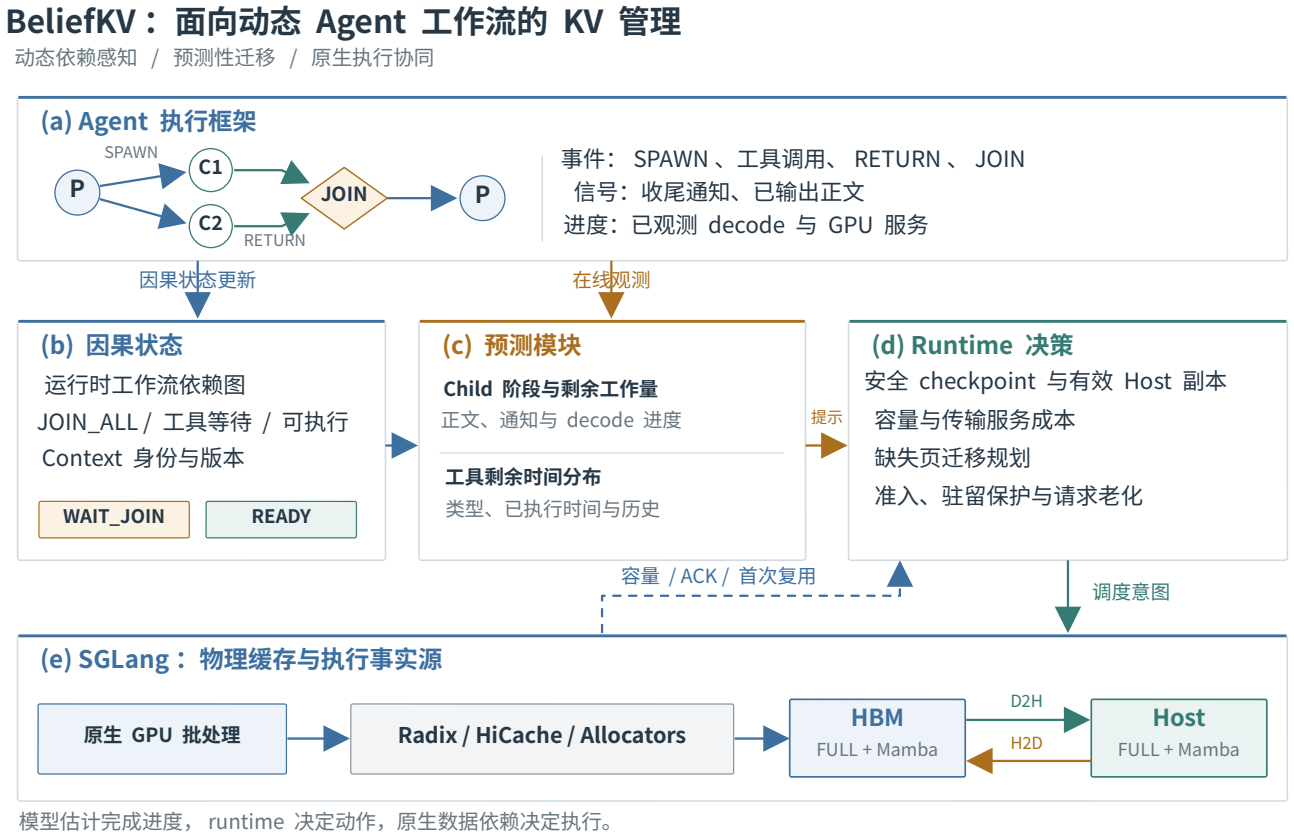
- **转向事件与内容驱动的预测**
  结合通知、语义、长度与 decode 进度，建立阶段与剩余工作预测。

10.05 - 10.11

- **推进原生对照与系统性能优化**
  原生对照与两波到达；优化增量备份、缺失页恢复、准入与容量交接。

目前：机制链路已贯通，稳定的端到端性能优势仍待验证。

关键进展：系统总体架构



从动态工作流到物理缓存与执行

捕获动态执行依赖

关联子任务、工具与 JOIN 事件，维护上下文和当前可执行状态。

融合完成信号与运行进度

结合通知、正文与 decode 进度，滚动预测 child / tool 的完成过程。

连接迁移决策与原生执行

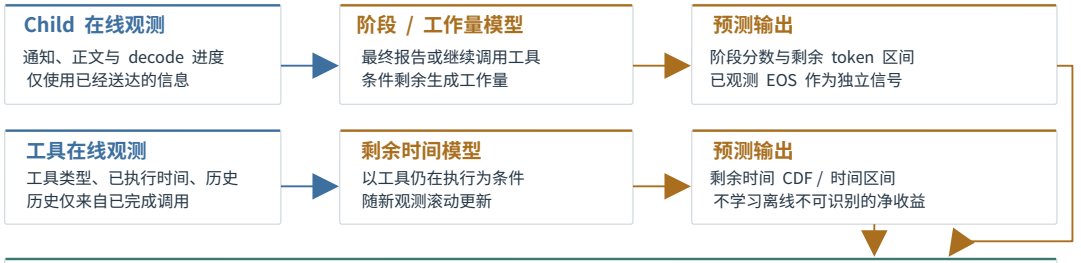
按缺失页迁移，协调驻留与准入；由 SGLang 管理物理数据依赖。

关键进展：预测与迁移协同

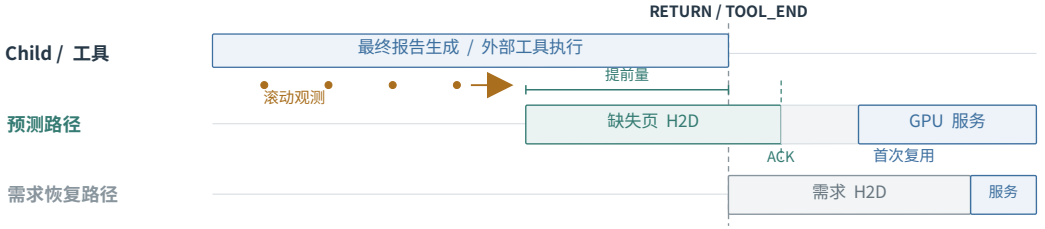
预测与调度协同

从完成信号到可被执行消费的预取

分离剩余工作量、调度机会与物理数据依赖



(b) 与工具等待或最终生成区间重叠



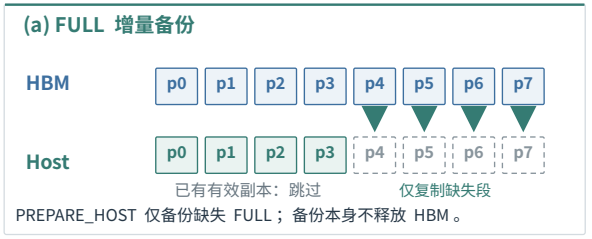
示意图，非实测加速。部分传输重叠也可利用；执行遵循原生数据依赖。

完成信号 → 滚动预测 → 恢复与执行

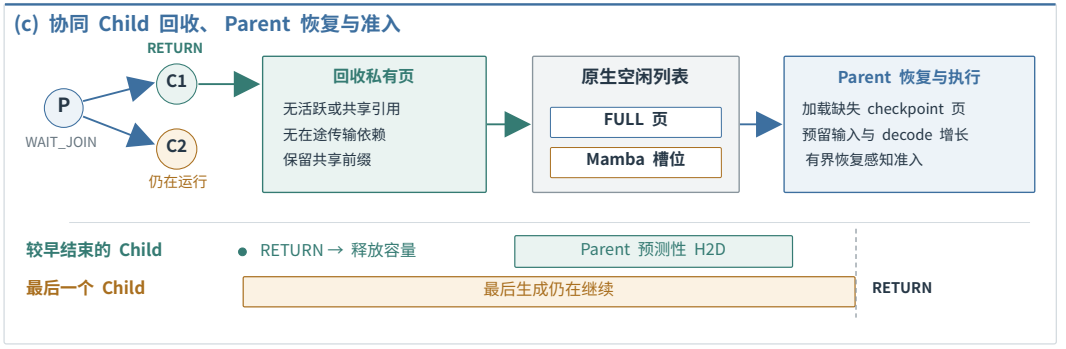
增量迁移与容量交接

增量迁移与 Child → Parent 容量交接

Agent 语义选择受益对象，原生页决定实际迁移范围







较早结束的 sibling 可支持 RETURN 前预取；最后一个 child 的容量只能在结束后使用。
回收容量通过原生分配器使用；共享页与仍在执行的页面保留。

缺失页备份 → child 回收 → parent 恢复

下月目标

聚焦：让预测式 KV 迁移带来可验证的端到端收益

01 **提高有效预取覆盖**

融合通知、正文与 decode 进度，改善 child / tool 完成预测。
覆盖更多 Host-only FULL 页，统计返回前恢复与下一请求实际复用。

02 **恢复与调度协同，降低额外开销**

联动容量回收、驻留与准入，减少重复加载和 ACK 后排队。
削减候选检查、前缀扫描与控制交付成本，避免抵消迁移收益。

03 **建立公平、稳定的性能证据**

同版本、同负载对比原生 SGLang，正式实验采用多轮平均。
综合报告繁忙窗口吞吐、成功工作流吞吐、配对 JCT 与重算。

验收：提高繁忙窗口与成功工作流吞吐，同时降低完成时间。